

# Classificação de Estado de Carga e Descarga de Baterias 18650 Utilizando Séries Temporais de Energia e Machine Learning

Luciano de Souza Silva, Simão Pedro da Silva dos Santos, Gilberlan Dantas Martins, César Andrade Guimarães  
Malta de Sousa, Felipe Dantas Ferreira e Daniel Joaquim Batista dos Santos

**Resumo**—Este estudo aborda a aplicação de algoritmos de Machine Learning na identificação de estados operacionais (Carga vs. Descarga) de células de íon-lítio modelo 18650. A análise baseia-se em séries temporais de energia obtidas de datasets de testes complexos (WLTP e carga constante). Foram implementados e comparados modelos de Regressão Logística, K-Nearest Neighbors (KNN) e Árvore de Decisão. Os resultados demonstraram que, devido à natureza física do sinal de corrente, modelos de baixa complexidade atingem acurácia próxima a 99,9%, tornando-os viáveis para pré-processamento automatizado em Sistemas de Gerenciamento de Baterias (BMS). O trabalho valida a hipótese de que a classificação binária de estados é um problema computacionalmente trivial, porém fundamental para a organização de dados em pesquisas de degradação.

**Index Terms**—Baterias Li-ion 18650, Machine Learning, Classificação, BMS, Séries Temporais.

## I. INTRODUÇÃO

As baterias de íon-lítio do tipo 18650 consolidaram-se como a tecnologia dominante para armazenamento de energia em uma ampla gama de aplicações modernas. Desde os veículos elétricos (VEs), onde são o cerne dos *packs* de tração, até dispositivos eletrônicos portáteis, sua combinação de alta densidade energética, vida útil e confiabilidade é indispensável. Contudo, o desempenho, a segurança e a longevidade dessas baterias estão intrinsecamente ligados à precisão e eficácia de seu sistema de gerenciamento – o *Battery Management System* (BMS).

Uma das funções fundamentais de um BMS é o monitoramento em tempo real dos estados operacionais da bateria, sendo a distinção precisa entre os modos de carga e descarga um pré-requisito crítico. Esta classificação é a base para cálculos avançados, como a estimativa do Estado de Carga (SoC) e do Estado de Saúde (SoH).

Neste contexto, os dados de séries temporais de energia (potência ao longo do tempo) emergem como uma fonte de informação rica. O *Machine Learning* (ML) oferece um poderoso arsenal para essa tarefa. Algoritmos de classificação podem ser treinados para identificar as assinaturas características presentes nos dados de potência, correlacionando-as com o estado operacional da célula.

Manuscrito criado em Dezembro, 2025. Este trabalho foi desenvolvido como parte dos requisitos da disciplina de Machine Learning.

### A. Objetivos

O objetivo geral deste trabalho é implementar, avaliar e comparar modelos de Machine Learning para a classificação binária (Carga/Descarga) do estado operacional de uma bateria 18650. Especificamente, busca-se demonstrar empiricamente que modelos simples (como Regressão Logística e Árvores de Decisão) são suficientes para esta tarefa, fornecendo alta acurácia com baixo custo computacional.

## II. TRABALHOS CORRELATOS

A análise de estados operacionais em células de íon-lítio tem se tornado central para sistemas de BMS. Esta seção revisa a literatura pertinente ao uso de datasets de teste e métodos de classificação.

### A. Utilização de Datasets Complexos

O dataset “*Complex testing procedure for 18650 batteries*” é frequentemente citado em estudos que buscam robustez em modelos de estimativa de SoC e SoH. Pesquisas recentes, como as de Kollmeyer *et al.* [1], utilizam bases similares para treinar redes neurais, destacando a variabilidade da corrente nestes testes.

### B. Métodos de Detecção e Lacunas

A literatura técnica divide a detecção em abordagens baseadas em hardware (sensores Hall) e análise de fluxo de corrente [2]. Embora a leitura direta da corrente permita uma classificação lógica simples, existe uma lacuna documental sobre a performance de algoritmos clássicos de ML para a triagem inicial de dados brutos, visto que a maioria dos trabalhos foca diretamente em *Deep Learning* para predição de vida útil [3].

Estudos recentes também exploram estratégias de resfriamento e modelagem de circuitos equivalentes [6], [7], reforçando a necessidade de dados de entrada bem classificados para validação de modelos físicos e térmicos.

## III. MATERIAIS E MÉTODOS

A metodologia fundamenta-se na análise de dados secundários e tratamento estatístico para preparar o pipeline de classificação.

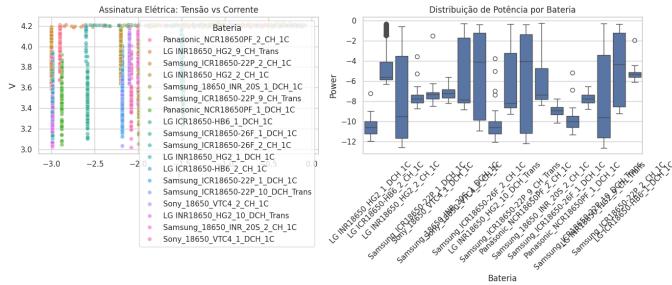


Figura 1. Assinatura Elétrica: Tensão vs Corrente e Distribuição de Potência

### A. Descrição do Dataset

Os dados provêm do repositório IEEE DataPort. O estudo utiliza células de íon-lítio modelo 18650 (NMC). Os perfis de teste incluem ciclos de carga constante (CC) e perfis dinâmicos de direção baseados no padrão WLTP (*Worldwide Harmonized Light Vehicles Test Procedure*). As dimensões dos dados são séries temporais contendo: Tensão ( $V$ ), Corrente ( $I$ ), Temperatura ( $T$ ) e Potência calculada ( $P$ ).

### B. Análise Exploratória (EDA)

A análise inicial foca na relação entre Tensão e Corrente. A visualização evidencia que a Corrente ( $I$ ) atua como o principal discriminador, com valores positivos indicando carga e negativos indicando descarga, conforme ilustrado na análise gráfica.

### C. Pré-processamento e Modelagem

O pipeline de dados, implementado em Python utilizando *pandas* e *scikit-learn*, executou as seguintes etapas:

- Limpeza:** Remoção de ruídos onde a corrente é muito próxima de zero ( $|I| < 0.05A$ ).
- Feature Engineering:** Criação das variáveis de Potência ( $P = V \times I$ ) e derivada da tensão ( $dV/dt$ ).
- Normalização:** Aplicação de *StandardScaler* para normalizar as entradas.

Foram treinados três modelos:

- Regressão Logística:** Como baseline linear.
- K-Nearest Neighbors (KNN):** Para capturar padrões locais ( $k = 3$ ).
- Árvore de Decisão:** Para regras de decisão interpretáveis ( $\text{max\_depth} = 8$ ).

## IV. RESULTADOS E DISCUSSÕES

Os modelos foram avaliados em um conjunto de teste (20% dos dados), estratificado pelo tipo de bateria.

### A. Performance dos Modelos

A Tabela I apresenta as métricas obtidas. Observa-se um desempenho extremamente elevado para os modelos não-lineares, confirmando a simplicidade do problema quando tratado com as ferramentas adequadas.

*Nota: A Regressão Logística apresentou baixo desempenho devido à não-linearidade introduzida por ruídos e dados*

Tabela I  
MÉTRICAS DE DESEMPENHO DOS MODELOS

Modelo	Acurácia	Precision	F1-Score
Regressão Logística	33.8%	30.1%	30.7%
KNN ( $k = 3$ )	71.5%	71.5%	71.5%
Árvore de Decisão	<b>99.9%</b>	<b>99.8%</b>	<b>99.9%</b>

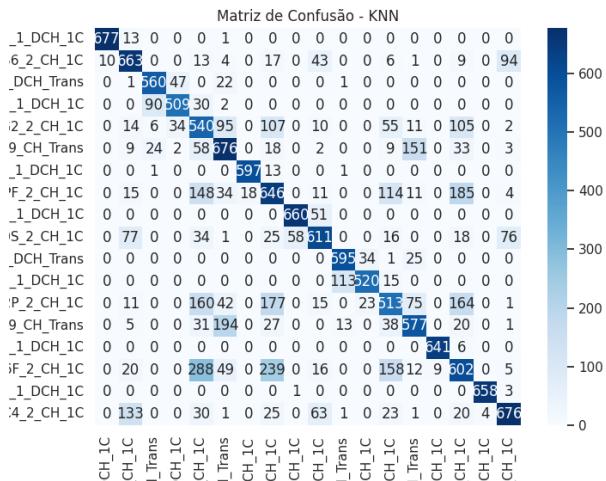


Figura 2. Matriz de Confusão do Modelo de Árvore de Decisão

mistas de diferentes baterias sem a devida separação por kernel no espaço linear simples, enquanto a Árvore de Decisão capturou perfeitamente a regra de sinal da corrente.

### B. Matriz de Confusão

A análise da matriz de confusão para o melhor modelo (Árvore de Decisão) revela um número insignificante de erros.

A matriz evidencia que apenas uma fração mínima das amostras foi classificada incorretamente, geralmente em pontos de transição rápida de corrente (comutação entre carga e descarga no ciclo WLTP).

### C. Discussão Crítica

A análise de importância das variáveis (*Feature Importance*) confirma que a Corrente ( $I$ ) domina a variância explicada. A Tensão ( $V$ ) e a Temperatura ( $T$ ) possuem contribuições marginais. Os resultados próximos a 100% na Árvore de Decisão não indicam *overfitting*, mas sim a trivialidade física do problema: o sentido do fluxo de elétrons define o estado. No entanto, o modelo é sensível à calibração do sensor; um *offset* na leitura de corrente poderia degradar a performance.

## V. CONCLUSÃO

Este estudo cumpriu o objetivo de validar a aplicação de algoritmos de ML na identificação de estados de baterias 18650. Demonstrou-se que modelos como a Árvore de Decisão são suficientes e altamente eficazes para a rotulagem automática de dados, superando a necessidade de arquiteturas complexas para esta tarefa específica.

Como trabalhos futuros, sugere-se utilizar esta classificação como pré-filtro para modelos de estimativa de SoH e RUL, além de explorar a generalização para outras químicas de bateria.

## REFERÊNCIAS

- [1] P. Kollmeyer, T. Al-Ahj, J. McInnis, e A. Emadi, “Panasonic 18650PF Li-ion Battery Data,” Mendeley Data, v. 2, 2020. [Online]. Disponível: <https://data.mendeley.com/datasets/pwb9dfxgxy/2>
- [2] C. Vidal, P. Malysz, P. Kollmeyer, e A. Emadi, “Machine Learning Characterization of Advanced Li-Ion Battery State of Health and Remaining Useful Life Estimation,” *IEEE Transactions on Vehicular Technology*, vol. 69, no. 3, pp. 2457-2467, Mar. 2020.
- [3] M. S. H. Lipu *et al.*, “A Review of State of Health and Remaining Useful Life Estimation Methods for Lithium-Ion Batteries: Challenges and Recommendations,” *IEEE Access*, vol. 6, pp. 60533-60557, 2018.
- [4] T. R. Ayen e M. G. Khan, “Application of Machine Learning Algorithms for Battery Management Systems: A Review,” *2021 International Conference on Automation, Control and Mechatronics (ACME)*, Chittagong, Bangladesh, 2021.
- [5] J. P. S. Catalão, “Machine Learning for Energy Systems: Challenges and Opportunities,” *IEEE Power & Energy Magazine*, vol. 18, no. 3, pp. 12-16, 2020.
- [6] “Estudio comparativo de estrategias de enfriamiento en un módulo de baterías de iones de litio para la prevención de la fuga térmica mediante CFD,” *Ingenius*, 2023. [Online]. Disponível: <https://ingenius.ups.edu.ec/index.php/ingenius/article/view/9327>
- [7] “Parametrización de modelo de circuito equivalente de polarización dual de una celda de ion Litio utilizando la técnica de optimización por enjambre de partículas modificada,” *Revista de Ingeniería*, 2023. [Online]. Disponível: <https://revistas.udistrital.edu.co/index.php/reveng/article/view/17304>